

Informe de Trabajo Práctico 2

Aprendizaje Profundo con aplicación a Visión Artificial

Laura Zúñiga Osorio

22 de octubre de 2025

1. Funciones de activación y gradientes. Se consideran las entradas y pesos:

$$x_1 = 2, \quad x_2 = 8, \quad w_1 = 1,45, \quad w_2 = -0,35, \quad b = -4$$

La entrada total a la neurona es:

$$x = w_1x_1 + w_2x_2 + b$$

$$x = (1,45)(2) + (-0,35)(8) - 4 = 2,90 - 2,80 - 4 = -3,90$$

Por lo tanto:

$$\boxed{x = -3,900}$$

A continuación se calculan las funciones de activación $f(x)$ y sus gradientes $f'(x)$, manteniendo tres decimales.

a. Función Sigmoide

$$f(x) = \frac{1}{1 + e^{-x}} = \frac{1}{1 + e^{3,9}}$$

$$e^{3,9} \approx 49,402$$

$$f(x) = \frac{1}{50,402} = 0,020$$

$$f'(x) = f(x)(1 - f(x)) = 0,020(1 - 0,020) = 0,020$$

$$\boxed{f(x) = 0,020, \quad f'(x) = 0,020}$$

b. Función Tangente Hiperbólica

$$f(x) = \tanh(-3,9)$$

$$\tanh(3,9) \approx 0,999$$

$$f(x) = -0,999$$

$$f'(x) = 1 - \tanh^2(x) = 1 - (-0,999)^2 = 1 - 0,998 = 0,002$$

$$\boxed{f(x) = -0,999, \quad f'(x) = 0,002}$$

c. Función ELU (Exponential Linear Unit) La definición empleada es:

$$f(x) = \begin{cases} x, & \text{si } x < 0 \\ \alpha(e^x - 1), & \text{si } x > 0 \end{cases}$$

Para $\alpha = 1$ y $x = -3,9 < 0$:

$$f(x) = x = -3,9$$

$$f'(x) = 1$$

$$\boxed{f(x) = -3,900, \quad f'(x) = 1,000}$$

d. Función Leaky ReLU Se define como:

$$f(x) = \max\left(\frac{x}{10}, x\right)$$

Para $x = -3,9$ se cumple $\frac{x}{10} = -0,39 < x$, por lo tanto:

$$f(x) = -0,39$$

$$f'(x) = \frac{1}{10} = 0,1$$

$$\boxed{f(x) = -0,390, \quad f'(x) = 0,100}$$

2. Perceptrón con dos neuronas. Los datos del problema son:

$$\mathbf{x} = (x_1, x_2) = (-3, 1, 1, 5), \quad W = \begin{bmatrix} -0,2 & 2 \\ -0,5 & -0,3 \end{bmatrix}, \quad b_1 = -4, \quad b_2 = -1.$$

Forward pass Entrada a la función sigmoide:

$$z_1 = w_{11}x_1 + w_{12}x_2 + b_1 = (-0,2)(-3,1) + (2)(1,5) + (-4) = -0,380,$$

$$z_2 = w_{21}x_1 + w_{22}x_2 + b_2 = (-0,5)(-3,1) + (-0,3)(1,5) + (-1) = 0,100.$$

Funciones activación (sigmoide):

$$a_k = \frac{1}{1 + e^{-z_k}} \rightarrow a_1 = 0,406, a_2 = 0,525.$$

Loss:

$$L = \frac{1}{2}(a_1^2 + a_2^2) = 0,220.$$

Backpropagation Derivadas de salida respecto al costo:

$$\frac{\partial C}{\partial a_1} = a_1 - t_1 = a_1 = 0,406, \quad \frac{\partial C}{\partial a_2} = a_2 - t_2 = a_2 = 0,525.$$

Derivada de la sigmoide:

$$\sigma'(z_k) = a_k(1 - a_k).$$

Valores:

$$\sigma'(z_1) = 0,406(1 - 0,406) = 0,098, \quad \sigma'(z_2) = 0,525(1 - 0,525) = 0,131.$$

Gradientes de C respecto a las pre-activaciones z_k :

$$\frac{\partial C}{\partial z_k} = \frac{\partial C}{\partial a_k} \sigma'(z_k).$$

Números:

$$\frac{\partial C}{\partial z_1} = 0,406 \cdot 0,098 = 0,098, \quad \frac{\partial C}{\partial z_2} = 0,525 \cdot 0,131 = 0,131.$$

Gradientes respecto a pesos y sesgos (regla de la cadena):

$$\frac{\partial C}{\partial w_{ij}} = \frac{\partial C}{\partial z_i} x_j, \quad \frac{\partial C}{\partial b_i} = \frac{\partial C}{\partial z_i}.$$

Valores (redondeados a tres decimales):

Para la neurona 1 (fila 1 de W):

$$\frac{\partial C}{\partial w_{11}} = 0,098 \cdot x_1 = 0,098 \cdot (-3,1) = -0,304,$$

$$\frac{\partial C}{\partial w_{12}} = 0,098 \cdot x_2 = 0,098 \cdot 1,5 = 0,147,$$

$$\frac{\partial C}{\partial b_1} = 0,098.$$

Para la neurona 2 (fila 2 de W):

$$\frac{\partial C}{\partial w_{21}} = 0,131 \cdot x_1 = 0,131 \cdot (-3,1) = -0,406,$$

$$\frac{\partial C}{\partial w_{22}} = 0,131 \cdot x_2 = 0,131 \cdot 1,5 = 0,196,$$

$$\frac{\partial C}{\partial b_2} = 0,131.$$